

Sprawozdanie z listy 4

Eksploatacja danych

Marta Stankiewicz (282244)

Paweł Nowak (282223)

2025-06-19

Spis treści

1	Zaawansowane metody klasyfikacji	2
1.1	Rodziny klasyfikatorów/uczenie zespołowe	2
1.2	Metoda wektorów nośnych (SVM)	4
1.3	Strojenie hiperparametrów modelu SVM	5
1.4	Wybór najskuteczniejszego modelu	6
2	Analiza skupień - algorytmy grupujące i hierarchiczne	7
2.1	Wybór i przygotowanie danych	7
2.2	Wizualizacja wyników grupowania	8
2.3	Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod	12
2.4	Interpretacja wyników grupowania – charakterystyki skupień	13

Spis rysunków

1	Porównanie skuteczności metod uczenia zespołowego	3
2	Porównanie wyników klasyfikacji SVM dla różnych jąder i parametrów kosztu	4
3	Porównanie dokładności i stabilności dostrojonego SVM opartego na jądrze radialnym	5
4	Klasteryzacja PAM ($k = 2$) z naniesionymi etykietami klas rzeczywistych	8
5	Dendrogram dla metody linkage average	9

6	Dendrogram dla metody linkage single	10
7	Dendrogram dla metody linkage complete	11
8	Porównanie algorytmów ze względu na średnią wartość indeksu silhouette . .	12
9	Wykresy pudełkowe wybranych cech z podziałem na skupienia	13
10	Wykresy pudełkowe wybranych cech z podziałem na skupienia	14
11	Wykresy pudełkowe wybranych cech z podziałem na skupienia	14
12	Wykresy pudełkowe wybranych cech z podziałem na skupienia	15
13	Wykresy pudełkowe wybranych cech z podziałem na skupienia	15

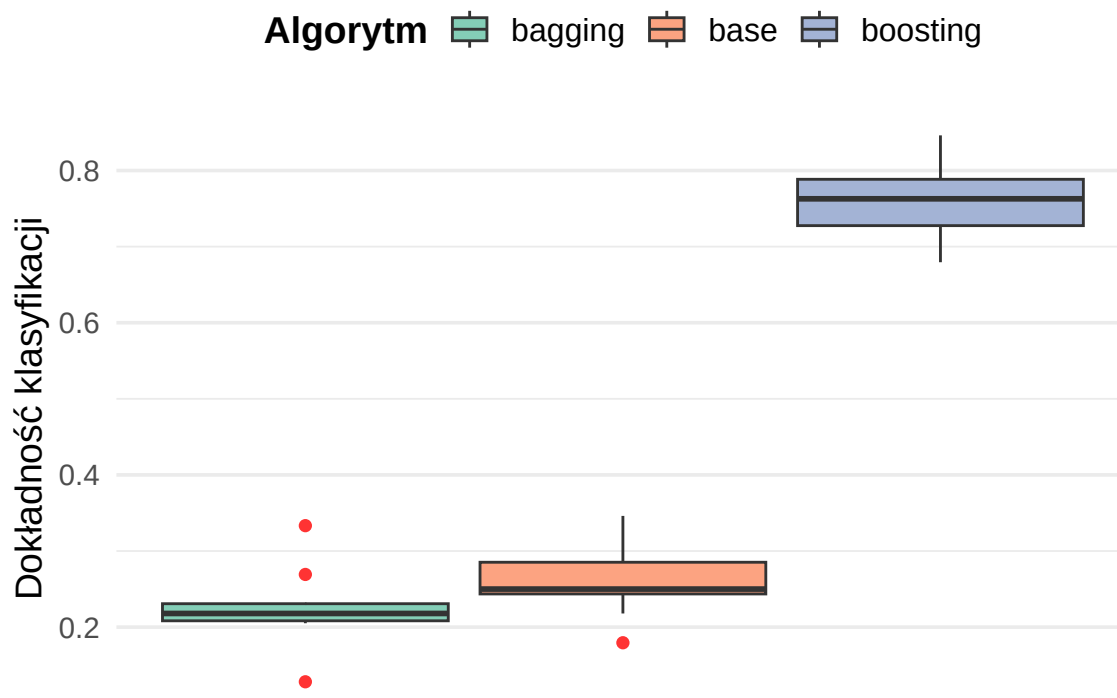
Spis tabel

1	Średnia dokładność i wariancja dla każdej z metod klasyfikacyjnych	3
2	Porównanie dokładności SVM z jądrem radialnym	6
3	Porównanie dokładności (accuracy) algorytmów grupowania	12
4	Średnie wartości cech w skupieniach	13
5	Analiza meoidów dla metody PAM	16

1 Zaawansowane metody klasyfikacji

1.1 Rodziny klasyfikatorów/uczenie zespołowe

Celem niniejszej analizy jest zbadanie wpływu metod zespołowych (ensemble learning) na jakość i stabilność klasyfikacji na przykładzie zbioru danych PimaIndiansDiabetes2. W szczególności skonstruujemy modele oparte na klasyfikatorze bazowym — drzewie decyzyjnym — oraz rozszerzymy je za pomocą trzech popularnych technik: baggingu, boostingu oraz random forest. Naszą hipotezą jest to, że zastosowanie tych metod zespołowych pozwoli na istotne zmniejszenie wariancji estymatora, co przełoży się na poprawę stabilności modelu oraz redukcję błędu klasyfikacji w porównaniu do pojedynczego drzewa decyzyjnego. Spodziewamy się, że agregacja wielu modeli (bagging i random forest) oraz sekwencyjne poprawianie błędów (boosting) przyczynią się do zwiększenia dokładności predykcji stanu zdrowia pacjentów. W dalszej części pracy przedstawimy wyniki eksperymentów, porównamy skuteczność poszczególnych metod oraz ocenimy, czy obserwowany spadek wariancji przekłada się na realną poprawę jakości klasyfikacji. Aby uzyskać rzetelną i stabilną estymatę błędu klasyfikacji dla każdej z wymienionych metod, proces uczenia oraz testowania modeli został powtórzony 10 razy. W każdej iteracji modele były trenowane na tym samym zbiorze treningowym, co pozwoliło na sprawiedliwe i porównywalne ocenienie skuteczności poszczególnych algorytmów. Dzięki temu możliwe było także zbadanie stabilności wyników oraz ocena wariancji błędu klasyfikacji dla każdej techniki.



Rysunek 1: Porównanie skuteczności metod uczenia zespołowego

Na podstawie wykresu 1 można sformułować kilka istotnych wniosków dotyczących porównywanych klasyfikatorów. Najwyższą średnią dokładnością charakteryzuje się metoda boosting, która wyraźnie przewyższa zarówno bagging, jak i klasyfikator bazowy. Co więcej, dla boostingu nie zaobserwowano wartości odstających w estymacjach dokładności, co dodatkowo świadczy o jego wysokiej stabilności.

Metoda bagging okazała się nieznacznie mniej skuteczna niż klasyfikator bazowy pod względem średniej dokładności, co może być zaskakujące w kontekście ogólnej skuteczności metod zespołowych. Warto jednak zwrócić uwagę, że wariancje wszystkich trzech podejść są do siebie bardzo zbliżone, co potwierdzają dane zawarte w tabeli 1.


Tabela 1: Średnia dokładność i wariancja dla każdej z metod klasyfikacyjnych

	base	bagging	boosting
<i>Accuracy</i>	0.2590	0.2256	0.7577
<i>Variance</i>	0.0022	0.0027	0.0025

1.2 Metoda wektorów nośnych (SVM)

W niniejszym podrozdziale przeanalizowana zostanie skuteczność jednego z bardziej zaawansowanych algorytmów klasyfikacyjnych — metody wektorów nośnych (ang. Support Vector Machine, SVM). W celu zapewnienia wszechstronności analizy, uwzględniono wpływ różnych funkcji jądra (liniowego, wielomianowego oraz radialnego) na jakość klasyfikacji. Dodatkowo rozważono, w jakim stopniu zmiana wartości parametru kosztu (ang. cost) przekłada się na dokładność działania algorytmu. Takie podejście pozwala lepiej zrozumieć, jak poszczególne konfiguracje SVM wpływają na efektywność klasyfikatora w kontekście analizowanego zbioru danych.

Dokładność SVM: jądra względem parametru cost



Rysunek 2: Porównanie wyników klasyfikacji SVM dla różnych jąder i parametrów kosztu

Na podstawie wykresu 2 można zauważyć, że dla każdej rozważanej wartości parametru kosztu najwyższą medianę dokładności osiąga klasyfikator SVM z jądrem liniowym. Wskazuje to na jego dobrą skuteczność niezależnie od przyjętej wartości parametru regularyzacji.

Największą niestabilnością, rozumianą jako duży rozrzut wyników, cechuje się natomiast metoda wykorzystująca jądro wielomianowe stopnia drugiego. Co istotne, dokładność tej konfiguracji systematycznie spada wraz ze wzrostem wartości parametru kosztu, co może świadczyć o podatności na przeuczenie w przypadku zbyt wysokiej penalizacji błędów.


Z kolei najbardziej stabilne wyniki — przy stosunkowo niskiej zmienności — uzyskuje klasyfikator oparty na jądrze radialnym. Biorąc pod uwagę właśnie ten aspekt, SVM z jądrem

RBF (radialnym) można uznać za najpewniejsze rozwiązanie pod względem powtarzalności działania.

1.3 Strojenie hiperparametrów modelu SVM

Dla klasyfikatora SVM z jądrem radialnym przeprowadzono proces strojenia parametrów: kosztu (C) oraz γ , w celu oceny, czy dostrajanie prowadzi do istotnego wzrostu dokładności modelu oraz redukcji jego wariancji. Wykres 3 przedstawia wykres pudełkowy, który umożliwia wizualną ocenę zarówno stabilności, jak i skuteczności klasyfikatora po strojeniu.

Aby umożliwić bardziej obiektywną ocenę wpływu strojenia, porównano wyniki uzyskane przez model dostrojony z rezultatami modelu niedostrojonego — dla tych samych wartości parametru C , przy domyślnej wartości γ . Wyniki tej analizy zostały zestawione w tabeli 2.



Rysunek 3: Porównanie dokładności i stabilności dostrojonego SVM opartego na jądrze radialnym

Jak pokazują wyniki zawarte w tabeli 2, średnia dokładność dostrojonego modelu SVM jest nieco niższa niż maksymalna dokładność osiągnięta wśród wszystkich konfiguracji przedstawionych w tabeli. Warto jednak zaznaczyć, że dostrojony model charakteryzuje się stosunkowo wysoką wariancją, co potwierdza konieczność podjęcia kompromisu między obciążonością modelu, a jego wariancją.

Tabela 2: Porównanie dokładności SVM z jądrem radialnym

Parametr C	Średnia Dokładność	Odchylenie Standardowe	Typ strojenia
0.1	0.7145	0.0246	untuned
1.0	0.7624	0.0390	untuned
10.0	0.7419	0.0197	untuned
100.0	0.7603	0.0358	tuned

Ostateczny wybór modelu zależy więc od priorytetów — czy zależy nam bardziej na maksymalizacji średniej dokładności, czy może na uzyskaniu większej stabilności i przewidywalności wyników. Jest to klasyczny przykład kompromisu (ang. trade-off) pomiędzy skutecznością a niezawodnością działania modelu.

1.4 Wybór najskuteczniejszego modelu

Wybór najskuteczniejszego modelu klasyfikacyjnego jest w dużej mierze kwestią subiektywną i zależy od przyjętego kryterium oceny. Można bowiem kierować się różnymi aspektami — takimi jak wysoka średnia dokładność klasyfikacji, bądź niska wariancja, która świadczy o stabilności modelu.

W niniejszej analizie jako główne kryterium przyjęto wysoką skuteczność klasyfikacyjną. W oparciu o to założenie, najlepszym rozwiązaniem okazała się metoda boosting, zastosowana w połączeniu z drzewem decyzyjnym jako klasyfikatorem bazowym. Zarówno jej skuteczność, jak i stabilność zostały przedstawione na wykresie 1.

2 Analiza skupień - algorytmy grupujące i hierarchiczne


2.1 Wybór i przygotowanie danych

Do analizy skupień wybrano zbiór danych PimaIndianDiabetes2, zawierający informacje medyczne dotyczące kobiet pochodzenia indiańskiego z grupy Pima, wraz z informacją o występowaniu cukrzycy. Aby ułatwić wizualizację wyników, z pełnego zbioru danych wybrano losowo 200 rekordów (niezawierających braków danych).

Przed rozpoczęciem analizy usunięto zmienną grupującą zawierającą etykiety klas, informującą o tym, czy dana osoba choruje na cukrzycę. Jej obecność mogłaby sztucznie zawyżyć jakość wyników, dlatego nie była brana pod uwagę przy samym grupowaniu. Zmienna ta zostanie jednak wykorzystana później do oceny jakości grupowania.

Ponieważ dane w zbiorze mają różne jednostki (np. liczba ciąż, poziom glukozy, BMI czy ciśnienie), przed wykonaniem analizy sprawdzono ich rozkład i zakresy wartości. Niektóre zmienne mogą mieć dużo większy wpływ na wyniki, jeśli nie zostaną wcześniej ustandaryzowane, dlatego zdecydowano się na standaryzację. W dalszej analizie zastosowane zostaną algorytmy PAM oraz AGNES, które opierają się na macierzy odległości – standaryzacja pozwala tu uniknąć dominacji zmiennych o większym rozrzucie. Warto zaznaczyć, że w niektórych przypadkach może ona osłabić naturalną separację grup, zwłaszcza jeśli pewne cechy mają szczególnie silne znaczenie informacyjne, jednak wybrane algorytmy są mniej podatne na ten efekt (niż np. metoda k-means).


2.2 Wizualizacja wyników grupowania




Rysunek 4: Klasteryzacja PAM ($k = 2$) z naniesionymi etykietami klas rzeczywistych

Na podstawie wykresu 4 przedstawiającego wyniki klasteryzacji metodą PAM (dla $k = 2$), widoczna jest częściowa zgodność uzyskanych klastrów z rzeczywistymi etykietami klasowymi (czyli obecnością lub brakiem cukrzycy). Choć algorytm zidentyfikował pewną strukturę w danych, separacja między grupami nie jest idealna – widoczna jest istotna liczba błędnych przypisań. Może to wynikać zarówno z częściowego nakładania się klas w przestrzeni cech, jak i z ograniczeń metody klasteryzacji.

Average linkage




Rysunek 5: Dendrogram dla metody linkage average



Rysunek 6: Dendrogram dla metody linkage single

Dendrogram – complete linkage



Rysunek 7: Dendrogram dla metody linkage complete

Na podstawie dendrogramów przedstawionych na wykresach 5, 6 oraz 7, które ilustrują wyniki hierarchicznej analizy skupień dla trzech różnych metod wiązania (average, single oraz complete linkage), można zauważyć wyraźne różnice w strukturze uzyskanych klastrów oraz w sposobie grupowania obiektów.


W przypadku metody average linkage, drzewo hierarchiczne ma dość zrównoważoną strukturę, a wysokości łączenia sugerują umiarkowany poziom podobieństwa między grupami. Ta metoda, jako kompromis pomiędzy single i complete linkage, prowadzi do stosunkowo czytelnej segmentacji – gałęzie są bardziej symetryczne, a różnice między klastrami umiarkowane. Ostatecznie uzyskane dwa główne klastry są względnie dobrze odseparowane, choć wciąż obecna jest pewna wewnętrzna różnorodność w obrębie skupień.

Z kolei dendrogram dla single linkage charakteryzuje się silnie wydłużoną strukturą, typową dla efektu „łańcucha”. W tym przypadku poszczególne punkty są łączone głównie na podstawie lokalnych, minimalnych odległości, co skutkuje powolnym narastaniem wysokości połączeń i brakiem wyraźnych granic między większymi grupami.

Dla porównania, dendrogram wygenerowany metodą complete linkage ukazuje znacznie bardziej zwartą i zrównoważoną strukturę klastrów. Maksymalna odległość między obserwacjami w obrębie jednego skupienia powoduje, że tworzone grupy są bardziej jednorodne i kompaktowe. W rezultacie granice między dwoma głównymi klastrami są tutaj najlepiej zarysowane spośród wszystkich trzech metod, co może świadczyć o większej odporności tej techniki na szum i wartości odstające.

Podsumowując, metoda complete linkage wydaje się najskuteczniejsza w kontekście analizy tej próbki danych, oferując najbardziej przejrzysty podział na dwa klastry. Average linkage również daje względnie użyteczną segmentację, choć z mniej wyraźnymi granicami. Natomiast single linkage nie zapewnia odpowiednio klarownego podziału i może prowadzić do mylących interpretacji, zwłaszcza przy danych o złożonej strukturze.

2.3 Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod



Rysunek 8: Porównanie algorytmów ze względu na średnią wartość indeksu silhouette

Tabela 3: Porównanie dokładności (accuracy) algorytmów grupowania

Algorytm	Dokładność (Accuracy)
AGNES (average)	0.715
AGNES (single)	0.715
AGNES (complete)	0.695
PAM	0.690

Z przedstawionych na wykresie 8 wyników wynika, że najbardziej optymalną liczbą klastrów

dla analizowanych danych jest $k=2$. Wartość współczynnika silhouette osiąga w tym przypadku maksimum dla większości zastosowanych metod, wskazując na najlepszą separację i spójność grup. W związku z tym, w dalszej analizie skupiono się na ocenie jakości grupowania dla dwóch klastrów, wykorzystując miarę zgodności partycji (funkcja `matchClasses()` z pakietu `e1071`). Jak pokazują wyniki w tabeli 3, najwyższą dokładność w odtwarzaniu rzeczywistej struktury klasowej osiągnął algorytm AGNES z metodą łączenia average.


Choć dendrogram dla metody complete linkage sugerował wyraźniejsze rozdzielenie grup, to metoda average linkage okazała się skuteczniejsza w praktycznej ocenie. Może to wynikać z faktu, że average linkage, opierając się na średnich odległościach między obiektami, lepiej radzi sobie z różnicami w gęstościach rozmieszczenia punktów i jest mniej podatna na wpływ obserwacji odstających niż complete linkage wykorzystujący maksymalne odległości.

2.4 Interpretacja wyników grupowania – charakterystyki skupień


W oparciu o wcześniejsze analizy (współczynnik silhouette, dokładność dopasowania) przyjęto $K=2$ jako optymalną liczbę skupień. Aby zrozumieć różnice między skupieniami, porównano średnie wartości cech oraz rozkłady (wykresy pudełkowe) wybranych z nich.

Tabela 4: Średnie wartości cech w skupieniach


Cluster	pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age
1	3.43	119.39	69.24	28.42	133.31	32.52	0.53	30.88
2	3.09	157.82	74.18	34.18	495.09	36.68	0.48	30.64




Rysunek 9: Wykresy pudełkowe wybranych cech z podziałem na skupienia




Rysunek 10: Wykresy pudełkowe wybranych cech z podziałem na skupienia



Rysunek 11: Wykresy pudełkowe wybranych cech z podziałem na skupienia



Rysunek 12: Wykresy pudełkowe wybranych cech z podziałem na skupienia



Rysunek 13: Wykresy pudełkowe wybranych cech z podziałem na skupienia

Jak przedstawiono w tabeli (dane bez standaryzacji, aby były bardziej zrozumiałe w realnym kontekście), największe różnice średnich wartości cech między klastrami obserwujemy dla zmiennych: glucose, pressure, triceps, insulin oraz mass — przy czym w klastrze drugim wartości te są wyraźnie wyższe. Warto jednak zauważyć, że średnia jest wrażliwa na wartości odstające, dlatego uzupełniając przeanalizowano również wykresy pudełkowe przedstawione na wykresach 9, 10, 11, 12, 13.

W szczególności, mediana zmiennej glucose w klastrze 2 jest znacznie wyższa niż w klastrze 1, co prowadzi do niemal idealnej separacji między tymi grupami. Również dla zmiennej

insulin różnice między klastrami są bardzo wyraźne. W przypadku cech takich jak mass, triceps oraz pressure rozkłady są bardziej zbliżone, jednak różnice nadal są zauważalne.

Taki układ jest zgodny z oczekiwaniami — glukoza i insulina należą do najważniejszych parametrów różnicujących osoby zdrowe i chore na cukrzycę, co znajduje odzwierciedlenie zarówno w analizie statystycznej, jak i wizualnej.

Warto jednak sprawdzić także, które obiekty są medoidami (reprezentantami skupień) w przypadku metody PAM i co je wyróżnia.

Tabela 5: Analiza meoidów dla metody PAM

	pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age
316	2	112	68	22	94	34.1	0.315	26
96	6	144	72	27	228	33.9	0.255	40

Analiza medoidów wyznaczonych metodą PAM (tabela ??) dla zbioru PimaIndiansDiabetes2 wykazała znaczące różnice w charakterystykach obu skupień. Medoid pierwszego skupienia (ID 96) cechuje się wysokimi wartościami zmiennych glucose (144) i insulin (228) przy jednoczesnej podwyższonej wartości mass (33.9). Medoid drugiego skupienia (ID 652) posiada zbliżoną wartość mass (33.8), ale istotnie niższe wartości glucose (117) i insulin (106).

Interesująca obserwacja dotyczy podobieństwa wartości mass przy jednoczesnych znaczących różnicach w pozostałych zmiennych. Wskazuje to, że sama analiza wskaźnika masy ciała nie pozwala na pełną charakterystykę różnic między skupieniami. Kluczowe dla rozróżnienia grup okazują się zmienne glucose i insulin, które wykazują istotnie różne wartości w obu medoidach.

Warto również odnotować różnicę w wartości age między medoidami (40 vs 27), co może sugerować zależność między wiekiem a wartościami innych analizowanych zmiennych. Ta obserwacja wymagałaby jednak dalszej weryfikacji na pełnym zbiorze danych.

Analiza medoidów potwierdza skuteczność metody PAM w identyfikacji wyraźnie różniących się grup obserwacji w zbiorze PimaIndiansDiabetes2.