

Sprawozdanie z listy 4

Eksploracja danych

Marta Stankiewicz (282244)

Paweł Nowak (282223)

2025-06-18

Spis treści

1	Zaawansowane metody klasyfikacji	2
1.1	Rodziny klasyfikatorów/uczenie zespołowe	2
1.2	Metoda wektorów nośnych (SVM)	4
1.3	Strojenie hiperparametrów modelu SVM	5
1.4	Wybór najskuteczniejszego modelu	6
2	Analiza skupień - algorytmy grupujące i hierarchiczne	6
2.1	Wybór i przygotowanie danych	6
2.2	Wizualizacja wyników grupowania	7
2.3	Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod	11

Spis rysunków

1	Porównanie skuteczności metod uczenia zespołowego	3
2	Porównanie wyników klasyfikacji SVM dla różnych jąder i parametrów kosztu	4
3	Porównanie dokładności i stabilności dostrojonego SVM opartego na jądrze radialnym	5
4	Klasteryzacja PAM ($k = 2$) z naniesionymi etykietami klas rzeczywistych	7
5	Dendrogram dla metody linkage average	8
6	Dendrogram dla metody linkage single	9
7	Dendrogram dla metody linkage complete	10

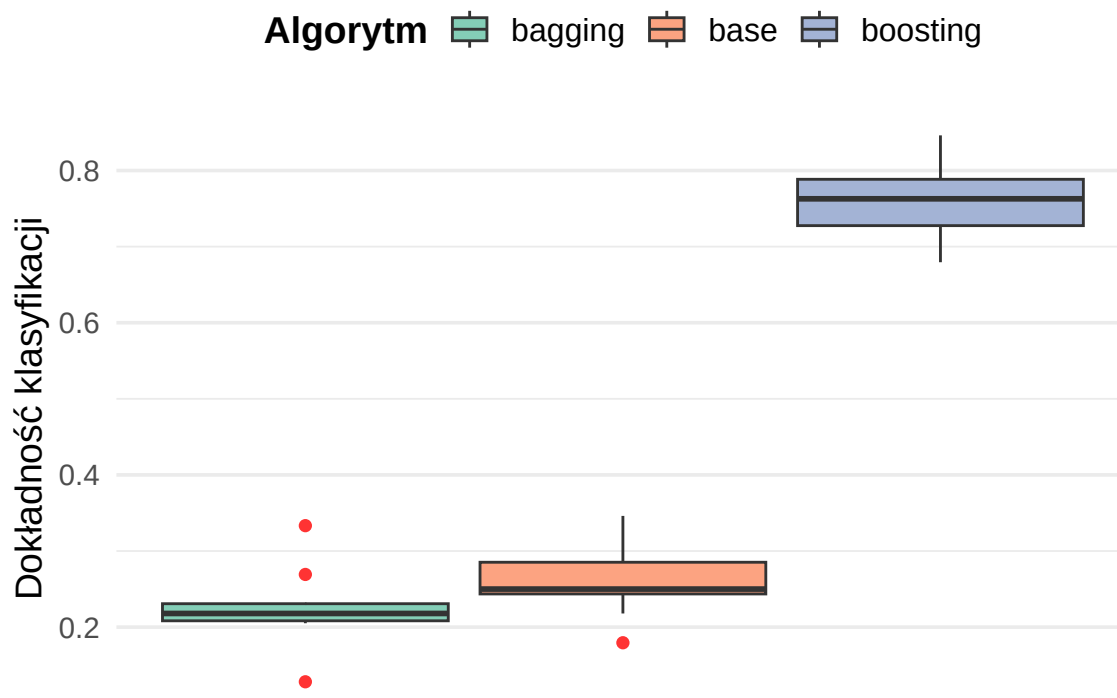
Spis tabel

1	Średnia dokładność i wariancja dla każdej z metod klasyfikacyjnych	3
2	Porównanie dokładności SVM z jądrem radialnym	6
3	Porównanie dokładności (accuracy) algorytmów grupowania	12

1 Zaawansowane metody klasyfikacji

1.1 Rodziny klasyfikatorów/uczenie zespołowe

Celem niniejszej analizy jest zbadanie wpływu metod zespołowych (ensemble learning) na jakość i stabilność klasyfikacji na przykładzie zbioru danych PimaIndiansDiabetes2. W szczególności skonstruujemy modele oparte na klasyfikatorze bazowym — drzewie decyzyjnym — oraz rozszerzymy je za pomocą trzech popularnych technik: baggingu, boostingu oraz random forest. Naszą hipotezą jest to, że zastosowanie tych metod zespołowych pozwoli na istotne zmniejszenie wariancji estymatora, co przełoży się na poprawę stabilności modelu oraz redukcję błędu klasyfikacji w porównaniu do pojedynczego drzewa decyzyjnego. Spodziewamy się, że agregacja wielu modeli (bagging i random forest) oraz sekwencyjne poprawianie błędów (boosting) przyczynią się do zwiększenia dokładności predykcji stanu zdrowia pacjentów. W dalszej części pracy przedstawimy wyniki eksperymentów, porównamy skuteczność poszczególnych metod oraz ocenimy, czy obserwowany spadek wariancji przekłada się na realną poprawę jakości klasyfikacji. Aby uzyskać rzetelną i stabilną estymatę błędu klasyfikacji dla każdej z wymienionych metod, proces uczenia oraz testowania modeli został powtórzony 10 razy. W każdej iteracji modele były trenowane na tym samym zbiorze treningowym, co pozwoliło na sprawiedliwe i porównywalne ocenienie skuteczności poszczególnych algorytmów. Dzięki temu możliwe było także zbadanie stabilności wyników oraz ocena wariancji błędu klasyfikacji dla każdej techniki.



Rysunek 1: Porównanie skuteczności metod uczenia zespołowego

Na podstawie wykresu 1 można sformułować kilka istotnych wniosków dotyczących porównywanych klasyfikatorów. Najwyższą średnią dokładnością charakteryzuje się metoda boosting, która wyraźnie przewyższa zarówno bagging, jak i klasyfikator bazowy. Co więcej, dla boostingu nie zaobserwowano wartości odstających w estymacjach dokładności, co dodatkowo świadczy o jego wysokiej stabilności.

Metoda bagging okazała się nieznacznie mniej skuteczna niż klasyfikator bazowy pod względem średniej dokładności, co może być zaskakujące w kontekście ogólnej skuteczności metod zespołowych. Warto jednak zwrócić uwagę, że wariancje wszystkich trzech podejść są do siebie bardzo zbliżone, co potwierdzają dane zawarte w tabeli 1.


Tabela 1: Średnia dokładność i wariancja dla każdej z metod klasyfikacyjnych

	base	bagging	boosting
<i>Accuracy</i>	0.2590	0.2256	0.7577
<i>Variance</i>	0.0022	0.0027	0.0025

1.2 Metoda wektorów nośnych (SVM)

W niniejszym podrozdziale przeanalizowana zostanie skuteczność jednego z bardziej zaawansowanych algorytmów klasyfikacyjnych — metody wektorów nośnych (ang. Support Vector Machine, SVM). W celu zapewnienia wszechstronności analizy, uwzględniono wpływ różnych funkcji jądra (liniowego, wielomianowego oraz radialnego) na jakość klasyfikacji. Dodatkowo rozważono, w jakim stopniu zmiana wartości parametru kosztu (ang. cost) przekłada się na dokładność działania algorytmu. Takie podejście pozwala lepiej zrozumieć, jak poszczególne konfiguracje SVM wpływają na efektywność klasyfikatora w kontekście analizowanego zbioru danych.

Dokładność SVM: jądra względem parametru cost



Rysunek 2: Porównanie wyników klasyfikacji SVM dla różnych jąder i parametrów kosztu

Na podstawie wykresu 2 można zauważyć, że dla każdej rozważanej wartości parametru kosztu najwyższą medianę dokładności osiąga klasyfikator SVM z jądrem liniowym. Wskazuje to na jego dobrą skuteczność niezależnie od przyjętej wartości parametru regularyzacji.

Największą niestabilnością, rozumianą jako duży rozrzut wyników, cechuje się natomiast metoda wykorzystująca jądro wielomianowe stopnia drugiego. Co istotne, dokładność tej konfiguracji systematycznie spada wraz ze wzrostem wartości parametru kosztu, co może świadczyć o podatności na przeuczenie w przypadku zbyt wysokiej penalizacji błędów.


Z kolei najbardziej stabilne wyniki — przy stosunkowo niskiej zmienności — uzyskuje klasyfikator oparty na jądrze radialnym. Biorąc pod uwagę właśnie ten aspekt, SVM z jądrem

RBF (radialnym) można uznać za najpewniejsze rozwiązanie pod względem powtarzalności działania.

1.3 Strojenie hiperparametrów modelu SVM

Dla klasyfikatora SVM z jądrem radialnym przeprowadzono proces strojenia parametrów: kosztu (C) oraz γ , w celu oceny, czy dostrajanie prowadzi do istotnego wzrostu dokładności modelu oraz redukcji jego wariancji. Wykres 3 przedstawia wykres pudełkowy, który umożliwia wizualną ocenę zarówno stabilności, jak i skuteczności klasyfikatora po strojeniu.

Aby umożliwić bardziej obiektywną ocenę wpływu strojenia, porównano wyniki uzyskane przez model dostrojony z rezultatami modelu niedostrojonego — dla tych samych wartości parametru C , przy domyślnej wartości γ . Wyniki tej analizy zostały zestawione w tabeli 2.



Rysunek 3: Porównanie dokładności i stabilności dostrojonego SVM opartego na jądrze radialnym

Jak pokazują wyniki zawarte w tabeli 2, średnia dokładność dostrojonego modelu SVM jest nieco niższa niż maksymalna dokładność osiągnięta wśród wszystkich konfiguracji przedstawionych w tabeli. Warto jednak zaznaczyć, że dostrojony model charakteryzuje się stosunkowo wysoką wariancją, co potwierdza konieczność podjęcia kompromisu między obciążonością modelu, a jego wariancją.

Tabela 2: Porównanie dokładności SVM z jądrem radialnym

Parametr C	Średnia Dokładność	Odchylenie Standardowe	Typ strojenia
0.1	0.7145	0.0246	untuned
1.0	0.7624	0.0390	untuned
10.0	0.7419	0.0197	untuned
100.0	0.7603	0.0358	tuned

Ostateczny wybór modelu zależy więc od priorytetów — czy zależy nam bardziej na maksymalizacji średniej dokładności, czy może na uzyskaniu większej stabilności i przewidywalności wyników. Jest to klasyczny przykład kompromisu (ang. trade-off) pomiędzy skutecznością a niezawodnością działania modelu.

1.4 Wybór najskuteczniejszego modelu

Wybór najskuteczniejszego modelu klasyfikacyjnego jest w dużej mierze kwestią subiektywną i zależy od przyjętego kryterium oceny. Można bowiem kierować się różnymi aspektami — takimi jak wysoka średnia dokładność klasyfikacji, bądź niska wariancja, która świadczy o stabilności modelu.

W niniejszej analizie jako główne kryterium przyjęto wysoką skuteczność klasyfikacyjną. W oparciu o to założenie, najlepszym rozwiązaniem okazała się metoda boosting, zastosowana w połączeniu z drzewem decyzyjnym jako klasyfikatorem bazowym. Zarówno jej skuteczność, jak i stabilność zostały przedstawione na wykresie 1.

2 Analiza skupień - algorytmy grupujące i hierarchiczne

2.1 Wybór i przygotowanie danych


Do analizy skupień wybrano zbiór danych PimaIndianDiabetes2, zawierający informacje medyczne dotyczące kobiet pochodzenia indiańskiego z grupy Pima, wraz z informacją o występowaniu cukrzycy. Aby ułatwić wizualizację wyników, z pełnego zbioru danych wybrano losowo 200 rekordów (niezawierających braków danych).

Przed rozpoczęciem analizy usunięto zmienną grupującą zawierającą etykiety klas, informującą o tym, czy dana osoba choruje na cukrzycę. Jej obecność mogłaby sztucznie zawyżyć jakość wyników, dlatego nie była brana pod uwagę przy samym grupowaniu. Zmienna ta zostanie jednak wykorzystana później do oceny jakości grupowania.

Ponieważ dane w zbiorze mają różne jednostki (np. liczba ciąż, poziom glukozy, BMI czy ciśnienie), przed wykonaniem analizy sprawdzono ich rozkład i zakresy wartości. Niektóre

zmienne mogą mieć dużo większy wpływ na wyniki, jeśli nie zostaną wcześniej ustandaryzowane, dlatego zdecydowano się na standaryzację. W dalszej analizie zastosowane zostaną algorytmy PAM oraz AGNES, które opierają się na macierzy odległości – standaryzacja pozwala tu uniknąć dominacji zmiennych o większym rozrzucie. Warto zaznaczyć, że w niektórych przypadkach może ona osłabić naturalną separację grup, zwłaszcza jeśli pewne cechy mają szczególnie silne znaczenie informacyjne, jednak wybrane algorytmy są mniej podatne na ten efekt (niż np. metoda k-means).


2.2 Wizualizacja wyników grupowania




Rysunek 4: Klasteryzacja PAM ($k = 2$) z naniesionymi etykietami klas rzeczywistych

Na podstawie wykresu 4 przedstawiającego wyniki klasteryzacji metodą PAM (dla $k = 2$), widoczna jest częściowa zgodność uzyskanych klastrow z rzeczywistymi etykietami klasowymi (czyli obecnością lub brakiem cukrzycy). Choć algorytm zidentyfikował pewną strukturę w danych, separacja między grupami nie jest idealna – widoczna jest istotna liczba błędnych przypisań. Może to wynikać zarówno z częściowego nakładania się klas w przestrzeni cech, jak i z ograniczeń metody klasteryzacji.

Average linkage




Rysunek 5: Dendrogram dla metody linkage average



Rysunek 6: Dendrogram dla metody linkage single

Dendrogram – complete linkage



Rysunek 7: Dendrogram dla metody linkage complete

Na podstawie dendrogramów przedstawionych na wykresach 5, 6 oraz 7, które ilustrują wyniki hierarchicznej analizy skupień dla trzech różnych metod wiązania (average, single oraz complete linkage), można zauważyć wyraźne różnice w strukturze uzyskanych klastrow oraz w sposobie grupowania obiektów.


W przypadku metody average linkage, drzewo hierarchiczne ma dość zrównoważoną strukturę, a wysokości łączenia sugerują umiarkowany poziom podobieństwa między grupami. Ta metoda, jako kompromis pomiędzy single i complete linkage, prowadzi do stosunkowo czytelnej segmentacji – gałęzie są bardziej symetryczne, a różnice między klastrami umiarkowane. Ostatecznie uzyskane dwa główne klastry są względnie dobrze odseparowane, choć wciąż obecna jest pewna wewnętrzna różnorodność w obrębie skupień.

Z kolei dendrogram dla single linkage charakteryzuje się silnie wydłużoną strukturą, typową dla efektu „łańcucha”. W tym przypadku poszczególne punkty są łączone głównie na podstawie lokalnych, minimalnych odległości, co skutkuje powolnym narastaniem wysokości połączeń i brakiem wyraźnych granic między większymi grupami.

Dla porównania, dendrogram wygenerowany metodą complete linkage ukazuje znacznie bardziej zwartą i zrównoważoną strukturę klastrow. Maksymalna odległość między obserwacjami w obrębie jednego skupienia powoduje, że tworzone grupy są bardziej jednorodne i kompaktowe. W rezultacie granice między dwoma głównymi klastrami są tutaj najlepiej zarysowane spośród wszystkich trzech metod, co może świadczyć o większej odporności tej techniki na szum i wartości odstające.

Podsumowując, metoda complete linkage wydaje się najskuteczniejsza w kontekście analizy tej próbki danych, oferując najbardziej przejrzysty podział na dwa klastry. Average linkage również daje względnie użyteczną segmentację, choć z mniej wyraźnymi granicami. Natomiast single linkage nie zapewnia odpowiednio klarownego podziału i może prowadzić do mylących interpretacji, zwłaszcza przy danych o złożonej strukturze.

2.3 Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod



```
## Direct agreement: 1 of 2 pairs
## Iterations for permutation matching: 1
## Cases in matched pairs: 71.5 %
```

```
## Direct agreement: 1 of 2 pairs
## Iterations for permutation matching: 1
## Cases in matched pairs: 71.5 %
```

```
## Direct agreement: 1 of 2 pairs
## Iterations for permutation matching: 1
## Cases in matched pairs: 69.5 %
```

```
## Direct agreement: 1 of 2 pairs
```

```
## Iterations for permutation matching: 1
## Cases in matched pairs: 69 %
```

Tabela 3: Porównanie dokładności (accuracy) algorytmów grupowania

Algorytm	Dokładność (Accuracy)
AGNES (average)	0
AGNES (single)	0
AGNES (complete)	0
PAM	0